



图像分割

内容介绍

1 K-means聚类

2 高斯混合模型 (GMM)

3 GrabCut




K-Means 聚类

将数据点随机分为K个聚类，查找每个聚类中心
(初始随机)


- 1 对每个数据点，计算每个点到聚类中心的距离
- 2 将数据点归为距离最近的类
- 3 重新计算每个聚类中心

重复步骤1到3，直至聚类中心不发生变化


K-Means聚类




K-Means聚类




K-Means聚类







K-Means聚类




K-Means聚类



K-Means聚类




K-Means聚类



K-Means聚类

■ RGB vector



K-means clustering minimizes $\sum_{i \in \text{clusters}} \left\{ \sum_{j \in \text{elements of } i\text{'th cluster}} \|x_j - \mu_i\|^2 \right\}$

K-means聚类

K-means所采用的这种算法称为期望最大化(Expectation-maximization, E-M), 它包含以下几个步骤:

1. 猜测一些簇中心点

2. 重复直至收敛



- 1) 期望步骤(E-step): 将点分配至离其最近的簇中心点

- 2) 最大化步骤(M-step): 将簇中心点设置为所有点坐标的平均值

期望步骤不断更新每个点是属于哪一个簇的期望值, 最大化步骤计算关于簇中心点的拟合函数值最大化对应坐标(argmax 函数), 在这个例子中通过简单地求每个簇中所有数据点坐标的平均值得到了簇中心点坐标。

K-means聚类

- 1.k-means不考虑方差。所谓方差，这里特指的是正态分布曲线的宽度。
- 2.k-means硬聚类，而高斯混合模型是软聚类。



内容介绍

1 K-means聚类

2 高斯混合模型 (GMM)

3 GrabCut

Gaussian模型


高斯模型是一种常用的变量分布模型，又称正态分布，是一种在自然界大量的存在的、最为常见的分布形式。

当样本数据 X 是一维数据时，高斯分布遵从下


$$p(x|\theta) = \frac{1}{\sqrt{2\pi}\alpha} \exp\left(-\frac{(x-u)^2}{2\alpha^2}\right)$$

u 为数据均值（期望）， α 为数据标准差（Standard deviation）。


在实际使用前，概率分布要先进行归一化，也就是说曲线下面的面积之和需要为1。



方差（确切地说是协方差）确定分布的形状



Gaussian模型



当样本数据 X 是多维数据 (Multivariate) 时, 高斯分布pdf为:

$$p(x|\theta) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{(x-u)^T \Sigma^{-1} (x-u)}{2}\right)$$

其中, u 为数据均值 (期望), Σ 为协方差 (Covariance), 描述各维变量之间的相关度, D 为数据维度。

GMM(高斯混合模型)

K-means的特点是硬聚类(hard clustering)，即将每个点分配给一个中心，且只能分配给一个(数据点属于某个簇类，要么为0，要么为1)。它的限制是没有提供数据点属于其他簇中心的概率或可能性的衡量方式，而这种软聚类(soft clustering)是GMM的组成部分。

高斯混合模型本质上与K-means是一致的，都使用了期望最大化方法，但是也有不同，具体过程如下：

- 1 随机选择初始簇中心位置和形状

- 2 重复至收敛

- 1) 期望步骤：为每个点找到对应的每个簇的概率作为权重


- 2) 最大化步骤：更新每个簇的位置，将其标准化,并且基于所有数据点的权重来确定形状。

GMM(高斯混合模型)

高斯混合模型可以看作是由 K 个单高斯模型组合而成的模型。


为什么要有混合高斯模型

一般来讲越靠近椭圆的中心样本出现的概率越大，这是由pdf决定的，但是这个高斯分布的椭圆中心的样本量却极少。显然样本服从单高斯分布的假设并不合理。



GMM(高斯混合模型)

- 这是用两个不同的高斯分布模型产生的数据。
- 通过求解两个高斯模型，并通过一定的权重将两个高斯模型融合成一个模型，即最终的混合高斯模型。这个混合高斯模型可以产生这样的样本。




GMM(高斯混合模型)

- 基本思想：用多个高斯分布函数去近似任意形状的概率分布，所以GMM就是由多个单高斯密度分布（Gaussian）组成的，每个Gaussian叫一个分量，这些分量线性加和即为 GMM 的概率密度函数。
- 将待聚类的数据点看成是分布的采样点，通过采样点利用类似极大似然估计的方法估计高斯分布的参数，求出参数（用EM算法求解）即得出了数据点对分类的隶属函数。

GMM(高斯混合模型)

高斯混合模型的概率分布为:

$$P(x|\theta) = \sum_{k=1}^K \alpha_k \phi(x|\theta_k)$$



图中每个点都由 K 个子模型中的某一个生成

对于这个模型而言, 参数 $\theta = (\tilde{\mu}_k, \tilde{\sigma}_k, \tilde{\alpha}_k)$, 也就是每个子模型的期望、方差 (或协方差)、在混合模型中发生的概率。

- x_j 表示第 j 个观测数据, $j = 1, 2, \dots, N$
- K 是混合模型中子高斯模型的数量, $k = 1, 2, \dots, K$
- α_k 是第 k 个子模型的概率, $\alpha_k \geq 0$, $\sum_{k=1}^K \alpha_k = 1$
- $\phi(x|\theta_k)$ 是第 k 个子模型的高斯分布密度函数, $\theta_k = (\mu_k, \sigma_k^2)$ 。其展开形式与上面介绍的单高斯模型相同
- γ_{jk} 表示第 j 个观测数据属于第 k 个子模型的概率

K是人工给定, 其他参数都需要通过EM算法进行估计

基于EM算法求解GMM中的参数

EM 算法，全称 Expectation Maximization Algorithm。期望最大算法是一种迭代算法，用于含有隐变量（Hidden Variable）的概率参数模型的最大似然估计或极大后验概率估计。

EM 算法分为两步：Expectation-Step 和 Maximization-Step。

- E-Step 通过观察数据和现有模型来估计参数，然后用这个估计的参数值来计算似然函数的期望值
- M-Step 是寻找似然函数最大化时对应的参数。

由于算法会保证在每次迭代之后似然函数都会增加，所以函数最终会收敛。

基于EM算法求解GMM中的参数

- 首先初始化参数
- E-step: 依据当前参数, 计算每个数据 j 来自子模型 k 的可能性

$$\gamma_{jk} = \frac{\alpha_k \phi(x_j | \theta_k)}{\sum_{k=1}^K \alpha_k \phi(x_j | \theta_k)}, j = 1, 2, \dots, N; k = 1, 2, \dots, K$$


- M-step: 计算新一轮迭代的模型参数

$$\mu_k = \frac{\sum_j^N (\gamma_{jk} x_j)}{\sum_j^N \gamma_{jk}}, k = 1, 2, \dots, K$$

$$\Sigma_k = \frac{\sum_j^N \gamma_{jk} (x_j - \mu_k)(x_j - \mu_k)^T}{\sum_j^N \gamma_{jk}}, k = 1, 2, \dots, K \quad (\text{用这一轮更新后的 } \mu_k)$$

$$\alpha_k = \frac{\sum_{j=1}^N \gamma_{jk}}{N}, k = 1, 2, \dots, K$$

- 重复计算 E-step 和 M-step 直至收敛 ($\|\theta_{i+1} - \theta_i\| < \varepsilon$, ε 是一个很小的正数, 表示经过一次迭代之后参数变化非常小)



内容介绍

1 K-means聚类

2 高斯混合模型 (GMM)

3 GrabCut

问题描述


- GrabCut是一种基于Graph Cut的图像分割算法，从待分割的对象周围用户指定的边界框开始，使用高斯混合模型估计目标对象和背景的颜色分布。在像素标签上构造带权重无向边的图模型，其能量函数优先选择具有相同标签的连接区域，并不断优化迭代求取最优解，GrabCut的用户操作和效果如下



- 输入：图像 $I(r,g,b)$ ，边界框
- 输出：前景图像

Graph


- 一般的无向图由顶点和边组成，即 $G = \langle V, E \rangle$ ， V 和 E 分别是顶点（vertex）和边（edge）的集合，每条边上对应一个权重。
- Graph Cut中的图（Graph）在一般无向图基础上添加多两个顶点，分别用符号 S 和 T 表示，统称为终端顶点，其他所有的顶点都必须和这两个顶点相连形成边集合中的一部分。



Graph


- Graph Cut图中的顶点和边各分为两种：
- 第一种顶点对应图像中的像素点，每两个邻域顶点（对应于图像中每两个邻域像素）的连接就是一条边，这种边称为n-links。
- 第二种顶点即为上述的终端顶点，分别为S（源点）和T（汇点）。每个普通顶点和这2个终端顶点之间都有连接，组成第二种边，称为t-links。

实线的边表示每两个邻域普通顶点连接的边n-links，
虚线的边表示每个普通顶点与s和t连接的边t-links。
在前后景分割中，s一般表示前景目标，t一般表示背景。




Graph

- 图中每条边上的权值为代价，对于图中的边集合 E 中的一个子集 C ，代价就是边子集 C 的所有边的权值的总和。
- 对图的边集合中的边进行断开生成S图和T图的操作，称为图的分割。
- 如果一个图分割，它的边集合所有权值之和最小，则称为最小图分割。




F	F	B
F	F	B
F	B	B




Graph

- s-t图的最小图分割把图的顶点划分为两个不相交的子集S和T，其中 $s \in S$, $t \in T$ 和 $S \cup T = V$ 。这两个子集就对应于图像的前景像素集和背景像素集，那就相当于完成了图像分割。




		
		
		
F	F	B
F	F	B
F	B	B



图像分割

图像分割看作一个图割问题，分割是一个节点标签问题



← 节点: 像素


← 边: 相邻像素之间的约束

给定了像素值和邻接关系，决定：

- 节点标签为前景或背景

图像分割

- 图像分割看成pixel labeling（像素标记）问题，目标（s-node）的label设为1，背景（t-node）的label设为0，这个过程可以通过最小化图割来最小化能量函数得到。
- 目标和背景边界处的cut就是我们想要的（相当于把图像中背景和目标连接的地方割开，那就相当于把其分割了）。



图像分割

边权值定义



- n-links权值：相邻两个像素颜色(c_i, c_j)越接近，权值越大

$$\omega_{ij} = \exp(-(c_i - c_j) / \sigma) \quad \sigma \text{ 是一个常量}$$

- t-links权值：像素属于前景或背景的概率

为前景和背景分别建立高斯颜色混合模型

$$\omega_i = -\log(p(c_i \mid \theta))$$




Grab-cuts 分割

1. 图的定义
 - 四连通或八连通
2. 计算相邻两个像素间边的权重
3. 设置像素属于背景或前景的概率
4. 应用最大流/最小割算法分割图像

GrabCut: 两步循环迭代


前背景模拟用高斯混合模型

- 要求有分割




分割用图割


- 有前背景模型



颜色模型



循环图割



高斯混合模型(典型的 5-8分量)

循环图割



用户初始化

$$\arg \min_{\theta}(\theta, S, C)$$

GMM学习颜色分布

$$\arg \min_S(\theta, S, C)$$

Graph cuts 分割图像

Initialisation

- User initialises trimap T by supplying only T_B . The foreground is set to $T_F = \emptyset$; $T_U = \overline{T_B}$, complement of the background.
- Initialise $\alpha_n = 0$ for $n \in T_B$ and $\alpha_n = 1$ for $n \in T_U$.
- Background and foreground GMMs initialised from sets $\alpha_n = 0$ and $\alpha_n = 1$ respectively.



Iterative minimisation

1. *Assign GMM components to pixels:* for each n in T_U ,

$$k_n := \arg \min_{k_n} D_n(\alpha_n, k_n, \theta, z_n).$$

2. *Learn GMM parameters from data $\mathbf{z}$:*

$$\underline{\theta} := \arg \min_{\underline{\theta}} U(\underline{\alpha}, \mathbf{k}, \underline{\theta}, \mathbf{z})$$

3. *Estimate segmentation:* use min cut to solve:

$$\min_{\{\alpha_n: n \in T_U\}} \min_{\mathbf{k}} \mathbf{E}(\underline{\alpha}, \mathbf{k}, \underline{\theta}, \mathbf{z}).$$

4. Repeat from step 1, until convergence.



结果



作业

一、填空题

- 1 K-means聚类的目标是最小化各类内的数据点到 聚类中心 的距离平方和。
- 1.GMM的全称是Gaussian Mixture Model。
- 2.在GrabCut中，用户初始标注一般使用 矩形框 工具框选前景区域。
- 3.GrabCut算法基于 图割 (Graph Cut) 模型，其中最小割用于 分割前景和背景。
- 4.K-means算法中常用的距离度量是 欧几里得 距离。

作业

二、单项选择题

1 GMM与K-means最主要的不同是：

A. GMM是基于图像纹理的 B. GMM表示概率分布 C. GMM不需要迭代 D. GMM速度更快

2 GrabCut算法主要通过以下哪种方式优化分割边界？

A. 均值漂移 B. 最小生成树 C. 最小割/最大流 D. 动态规划

3 在GMM中，参数估计通常使用哪种算法？

A. PCA B. KNN C. EM算法 D. LDA

作业

三、判断题

- (×) K-means可以有效处理非凸形状的数据聚类问题。
- (√) GMM可以表示一个类别中存在多个子分布的情况。
- (√) GrabCut不能处理用户完全不提供任何前景信息的图像。
- (√) EM算法中的E步用于估计隐藏变量的后验概率分布。
- (√) 图割算法是通过最小化能量函数来进行图像分割的。
- (×) GrabCut只能处理灰度图像，无法处理彩色图像。

作业

四、计算题

1. K-means聚类步骤

给定以下3个像素点的颜色特征 (R, G) 为:

$P1 = (100, 50)$, $P2 = (102, 52)$, $P3 = (200, 180)$

若聚类数 $K=2$, 初始中心 $C1 = P1$, $C2 = P3$ 。

请执行一次K-means聚类的“分配步骤” (Assignment Step), 并说明每个点被分配到哪个簇中心。

2. GMM概率计算

已知某图像像素强度为 $x=128$, 假设GMM中一个高斯分布分量的均值 $\mu=120$, 方差 $\sigma^2=64$, 混合系数为0.4。请计算该高斯分量对 $x=128$ 的概率密度值 (写出公式并代入计算), 以及其加权后对整体GMM贡献。

3. GrabCut图构建

简述GrabCut中构建图 (Graph) 时的两个主要边 (t-link和n-link) 分别表示什么, 并说明其作用。

1. K-means聚类步骤

- 点: $P1=(100,50)$, $P2=(102,52)$, $P3=(200,180)$
- 初始中心: $C1=P1$, $C2=P3$
- 欧式距离计算如下:

$$d(P1, C1) = 0, \quad d(P1, C2) = \sqrt{(100 - 200)^2 + (50 - 180)^2} \approx 166.4$$

$$d(P2, C1) = \sqrt{(2)^2 + (2)^2} = \sqrt{8} \approx 2.83, \quad d(P2, C2) \approx \sqrt{(98)^2 + (128)^2} \approx 161.7$$

$$d(P3, C1) \approx 166.4, \quad d(P3, C2) = 0$$

分配结果: $P1 \rightarrow C1$, $P2 \rightarrow C1$, $P3 \rightarrow C2$

2. GMM概率计算

- 参数: $x=128$, $\mu=120$, $\sigma^2=64 \rightarrow \sigma=8$, 混合系数 $\alpha=0.4$
- 高斯概率密度公式:

$$p(x) = \frac{1}{\sqrt{2\pi} \cdot \sigma} \cdot \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$p(128) = \frac{1}{\sqrt{2\pi} \cdot 8} \cdot \exp\left(-\frac{(128 - 120)^2}{2 \cdot 64}\right) = \frac{1}{20.07} \cdot \exp(-0.5) \approx 0.0499 \cdot 0.6065 \approx 0.0303$$

- 加权贡献为: $0.4 \times 0.0303 \approx \mathbf{0.0121}$

3. GrabCut图构建

- **t-link (终端边)**：连接像素与源（前景）或汇（背景），用于表示像素属于前景或背景的代价。
- **n-link (邻接边)**：连接相邻像素之间，表示它们相似度（颜色差异小则权重大），用于保持边界平滑。
- 作用：构建图后通过最小割分出代价最小的前景/背景分割。

K-means与GMM优缺点对比

- K-means优点：简单、速度快。缺点：只能处理线性可分、簇形状固定（球形）。
- GMM优点：能处理复杂分布，提供概率输出。缺点：对初始参数敏感、计算较慢。